Detección de Videos Inapropiados para Niños en YouTube

1er Mariela Ocampo
Ciencia de la Computación
UTEC
Lima, Perú
mariela.ocampo@utec.edu.pe

2do María Lazón
Ciencia de Datos
UTEC
Lima, Perú
maria.lazon@utec.edu.pe

3er Leonardo Chocce
Sistemas de la Información
UTEC
Lima, Perú
leonardo.chocce@utec.edu.pe

4to Adrián Urbina
Ciencia de Datos
UTEC
Lima, Perú
adrian.urbina@utec.edu.pe

***Resumen*—Muchos videos de YouTube con apariencia infantil contienen escenas violentas, sexuales o perturbadoras (fenómeno Elsagate), y la revisión humana no alcanza para el volumen de la plataforma. Este trabajo estudia si es posible clasificar videos dirigidos a niños como *suitable*, *disturbing*, *restricted* o *irrelevant* usando solo sus metadatos: título, descripción, tags, duración y métricas de interacción. Se usa el ground truth de 4,797 videos etiquetados por humanos de Papadamou *et al.*, con una partición y una validación cruzada agrupadas por canal para evitar que el modelo reconozca canales ya vistos. Se compararon un baseline de clase mayoritaria, regresión logística y Naive Bayes sobre TF-IDF, Random Forest y LightGBM sobre metadatos, y modelos combinados de texto y metadatos. El mejor modelo, una regresión logística sobre TF-IDF y metadatos, alcanzó en prueba un F1 macro de 0.725 (frente a 0.138 del baseline de clase mayoritaria en el mismo conjunto) y un AUC macro de 0.914, aunque no detectó el 28.6 % de los videos *disturbing* ni el 45.0 % de los *restricted*. Aplicado a 839,905 videos sin etiquetar, el modelo genera muchas más alertas que el clasificador original, sobre todo en contenido popular no infantil. Los resultados indican que los metadatos permiten priorizar la revisión humana, pero no reemplazarla.**

***Palabras clave*—clasificación de texto, moderación de contenido, seguridad infantil, YouTube, Elsagate, TF-IDF**

I. Introducción y Formulación del Problema

I-A. Descripción y motivación del problema

El acceso de niños pequeños a plataformas de video como YouTube es masivo y creciente. Actualmente se suben más de 500 horas de video por minuto a YouTube, lo que ilustra la escala del contenido disponible [1]. Aunque existe una gran cantidad de videos dirigidos al público infantil, muchos materiales con apariencia infantil contienen escenas o temas inadecuados: violencia, lenguaje ofensivo, sexualización o imágenes perturbadoras. Este problema fue identificado como Elsagate, donde videos con personajes de dibujos animados populares (Peppa Pig, Spider-Man, Elsa, etc.) mostraban situaciones grotescas u obscenas dirigidas a niños de 2 a 6 años [2]. Estas producciones emplean entornos coloridos y palabras clave infantiles, pero en realidad incluyen contenidos potencialmente dañinos o perturbadores para los niños, como mutilaciones, inyecciones o escenas de miedo [2].

Debido al enorme flujo de contenido, con miles de millones de videos subidos y cientos de miles nuevos cada día, la revisión humana exhaustiva es inviable. Plataformas como YouTube han empezado a usar aprendizaje automático para ayudar en la moderación de contenidos y aplicar restricciones de edad automáticamente [3]. En este contexto, proponemos desarrollar un modelo de aprendizaje supervisado capaz de detectar y clasificar automáticamente videos potencialmente inapropiados para niños en YouTube, usando sus metadatos y textos asociados.

El proyecto dispone de un conjunto de datos de referencia con 4,797 videos etiquetados manualmente en cuatro clases: *suitable*, *disturbing*, *restricted* e *irrelevant* [4], cuyas definiciones se detallan en la Sección II-B. Además, se cuenta con un corpus más amplio para extender el análisis a gran escala. El análisis exploratorio de los datos revela patrones en títulos, etiquetas, duración, categorías de YouTube y métricas de interacción que diferencian parcialmente estas clases. El principal desafío del proyecto es distinguir contenido infantil legítimo de aquellos videos engañosos que, bajo apariencia de material infantil (personajes conocidos, colores, juguetes), ocultan elementos inadecuados [2]. Esta tarea es compleja porque los creadores malintencionados pueden modificar ligeramente el contenido y las plataformas públicas evolucionan continuamente.

La motivación combina el alto volumen de contenido infantil, que hace inviable la supervisión manual total; la dificultad de filtrar videos engañosos que parecen inocuos; y la importancia social de proteger a los niños y facilitar el trabajo de padres, tutores y plataformas. El objetivo es crear una herramienta de apoyo que agilice la detección de videos sospechosos, analice volúmenes masivos de información y contribuya a una clasificación más eficiente. No se busca reemplazar la supervisión humana, sino ayudarla haciendo más rápida y precisa la preclasificación de contenido potencialmente problemático.

I-B. Objetivos del proyecto

Objetivo general. Desarrollar un modelo de aprendizaje supervisado que clasifique automáticamente videos de YouTube según su idoneidad para niños pequeños (*suitable*, *irrelevant*, *restricted*, *disturbing*) a partir de sus metadatos, como herramienta de apoyo a la moderación de contenido.

Objetivos específicos.

1. Caracterizar el dataset *Disturbed YouTube for Kids* mediante un análisis exploratorio: estructura, valores

faltantes, outliers, desbalance de clases, relaciones entre variables y riesgos de fuga de datos.
2. Diseñar el preprocesamiento y la ingeniería de características a partir del texto y de las métricas de interacción.
3. Entrenar y comparar un baseline y al menos dos enfoques de modelado, con una validación que agrupe por canal.
4. Evaluar el desempeño con métricas apropiadas para clases desbalanceadas, con énfasis en el recall de *disturbing* y *restricted*, y analizar los errores.
5. Comprobar la consistencia de las predicciones del modelo sobre los conjuntos adicionales, que no tienen etiquetas humanas fuera del ground truth.

I-C. Definición de la tarea de aprendizaje automático

Se plantea un modelo de aprendizaje supervisado que, a partir de los metadatos y textos asociados a cada video, prediga su clase de adecuación para niños. Para cada video v se define un vector de características $\mathbf{x}_v$ construido a partir de sus metadatos, que representan distintos aspectos del video:

- **Texto asociado:** título, descripción y etiquetas (tags).
- **Categoría:** categoría de YouTube (por ejemplo, Educación o Entretenimiento).
- **Características del video:** duración y calidad de la imagen (definición).
- **Métricas de interacción:** visualizaciones, likes, dislikes y comentarios, que reflejan la popularidad y la respuesta del público.

El identificador y el nombre del canal no se incluyen como características, para evitar que el modelo memorice rasgos propios de cada canal (Sección II-J); el canal se usa únicamente para agrupar la partición de los datos.

A partir de estas características, el modelo aprende una función de predicción. Formalmente, la tarea se expresa como

$$\hat{y}_v = f(\mathbf{x}_v), \tag{1}$$

donde $\hat{y}_v \in \mathcal{Y}$ es la clase predicha para el video v, con $\mathcal{Y}$ el conjunto de las cuatro clases (*suitable*, *disturbing*, *restricted* e *irrelevant*), y $f\colon \mathbb{R}^n \to \mathcal{Y}$ opera sobre las características ya vectorizadas. El modelo busca que $\hat{y}_v$ coincida con la etiqueta real y_v del conjunto de entrenamiento. Se aborda como un problema de clasificación multiclase supervisada, dado que se cuenta con etiquetas manuales.

Para entrenar el modelo se emplean los 4,797 videos etiquetados. La función f puede implementarse con distintos algoritmos de clasificación (por ejemplo, regresión logística multiclase, árboles de decisión, ensamblajes o redes neuronales). El modelo entrenado se evalúa una sola vez en un conjunto de prueba independiente, reservado del ground truth (Sección V-A). Se presta especial atención al desempeño en las clases *disturbing* y *restricted*, ya que clasificar erróneamente estos videos como seguros tendría consecuencias más graves.

Se consideró también predecir un puntaje continuo de inapropiación ($y_v \in [0, 1]$) como tarea de regresión, pero se descartó porque las etiquetas disponibles son categóricas; en su lugar, las probabilidades por clase del modelo permiten ordenar los videos por riesgo para priorizar la revisión humana.

Los pasos generales del pipeline son:

1. Extracción automática de características $\mathbf{x}_v$ de cada video (a partir de metadatos y texto).
2. Preprocesamiento y normalización de datos.
3. Entrenamiento del modelo de aprendizaje supervisado con las etiquetas conocidas.
4. Evaluación con validación cruzada y en el conjunto de prueba separado.
5. Análisis de resultados (matriz de confusión, métricas) y ajuste de parámetros según corresponda.

Adicionalmente, aunque la tarea principal se centra en metadatos, la incorporación de características audiovisuales extraídas directamente del contenido (por ejemplo, tasa de cambios de escena, movimiento, estadísticas de audio) queda como extensión (Sección IX), porque representa un esfuerzo adicional significativo; en este trabajo se priorizan las fuentes de información más accesibles: texto, etiquetas y métricas del video.

Por el desbalance de clases, la métrica principal es el F1 macro, acompañada del recall por clase (en particular en *disturbing* y *restricted*), AUC-ROC, *average precision* y la matriz de confusión; la exactitud se reporta solo como referencia (Sección V-B).

I-D. Preguntas de investigación e hipótesis

Se plantean las siguientes preguntas de investigación, cada una con su hipótesis:

- **PI1 (central):** ¿Es posible predecir si un video dirigido al público infantil es apropiado, perturbador o restringido utilizando únicamente metadatos (título, descripción, tags), duración y métricas de interacción (vistas, likes, comentarios), sin necesidad de procesar el video o el audio directamente?
  H1: Las señales textuales y de interacción contienen información suficiente para distinguir entre clases con un desempeño claramente superior al de un modelo base ingenuo (por ejemplo, uno que siempre prediga la clase mayoritaria, *irrelevant*).
- **PI2 (generalización):** Excluyendo los videos que ya forman parte del ground truth de entrenamiento (para evitar fuga de datos), ¿qué proporción de los videos nuevos de `elsagate_related`, un escenario de alto riesgo, predice el modelo como inapropiados, y qué tan consistente es con la predicción del clasificador original de los autores?
  H2: Como fuera del ground truth el clasificador original predijo como inapropiados solo 1,260 de 230,873 videos de este conjunto (0.55 %; Sección II-I), se espera que el modelo también prediga una proporción baja, y las discrepancias se revisarán de forma cualitativa.
- **PI3 (comprobación de consistencia):** Excluidos los solapamientos con el ground truth, ¿mantiene el modelo una proporción baja de videos predichos como inapropiados en `other_child_related`, `random_videos`

y `popular_videos`, donde el clasificador original predijo como inapropiados el 0.43 %, el 0.73 % y el 0 % de los videos, respectivamente?

H3: Se espera una proporción baja y del mismo orden que la del clasificador original, aunque podría aumentar levemente por el cambio de distribución entre conjuntos.

Como fuera del ground truth no existen etiquetas humanas, PI2 y PI3 se responden como comprobaciones de consistencia y no como medidas de recall o de tasa de falsos positivos (Sección VI-E).

II. Datos y Análisis Exploratorio de Datos

II-A. Descripción del dataset

El dataset utilizado proviene de Papadamou et al. [4], presentado en la 14th International AAAI Conference on Web and Social Media (ICWSM 2020) y publicado en Zenodo [5]. Los datos fueron recolectados mediante la YouTube Data API [6] y consisten en metadatos de video, no en el contenido audiovisual en sí. El equipo trabaja con tres formas del mismo dataset:

- `dataset_groundtruth.csv`: versión tabular del ground truth, con 4,797 videos etiquetados manualmente por humanos. Es la fuente principal de entrenamiento y de evaluación formal (partición de prueba reservada y validación cruzada).
- `dataset_consolidado_parts/`: 844,702 videos únicos, particionados en 10 archivos `.csv.gz`, que integran los conjuntos adicionales (`elsagate_related`, ∼233K videos; `other_child_related`, ∼155K; `random_videos`, ∼482K; y `popular_videos`, ∼11K). Se usan para la comprobación de consistencia con el modelo entrenado (Sección VI-E); no tienen etiquetas humanas, salvo los videos que también están en el ground truth.
- Archivos JSON crudos comprimidos: formato original de la API, previo a la conversión a CSV.

El `dataset_groundtruth.csv` contiene 4,797 videos, sin duplicados (`video_id` único), y 22 variables. El análisis se dividió en dos partes: un análisis completo del ground truth y un análisis breve de las primeras 1,000 líneas del primer archivo JSON de cada conjunto adicional (no de muestras aleatorias). Se utilizó Python con Pandas, Matplotlib y Seaborn en Jupyter Notebook.

II-B. Variables y variable objetivo

Las 22 variables se agrupan en: identificadores (`video_id`, `channel_id`, `channel_title`); texto (`title`, `description`, `tags`); fecha de publicación; duración (`duration_seconds` y su versión ISO 8601); categóricas (`category_id` con 17 valores, `definition`, `caption`, `licensed_content`); métricas de interacción (`view_count`, `like_count`, `dislike_count`, `comment_count` y `favorite_count`, siempre 0); la variable objetivo `classification_label`; y tres columnas de control (`prediction`, vacía en el ground truth, `is_ground_truth` y `source_dataset`, ambas constantes).

La variable objetivo es `classification_label`, que asigna a cada video una de cuatro clases, definidas por los autores del dataset según el tipo de contenido y su público objetivo:

- *Suitable* (apto): contenido apropiado para niños de 1 a 5 años y relevante para sus intereses (caricaturas, canciones infantiles, videos educativos).
- *Disturbing* (perturbador): videos dirigidos a este mismo público, pero que contienen elementos inapropiados (insinuaciones sexuales, lenguaje abusivo, violencia gráfica, escenas de miedo, etc.); es el caso central del fenómeno Elsagate.
- *Restricted* (restringido): contenido no dirigido a niños pequeños, pero inapropiado para menores de 17 años en general (violencia explícita, lenguaje inapropiado, contenido sexual, consumo de drogas o alcohol).
- *Irrelevant* (no relevante): contenido apropiado pero no dirigido a niños pequeños (por ejemplo, videos de videojuegos o música dirigidos a públicos mayores).

Esta clasificación no equivale directamente a una escala binaria "apto/no apto": *suitable* e *irrelevant* son ambos apropiados (solo difieren en el público al que apuntan), mientras que *disturbing* y *restricted* representan contenido problemático. La distribución de clases se presenta en la Sección II-C. Esta variable fue elegida como objetivo porque es la única etiqueta verificada por humanos en el dataset (a diferencia de `prediction`, que proviene de un clasificador externo) y porque responde directamente a la pregunta de investigación central del proyecto.

II-C. Distribución de clases y desbalance

El ground truth contiene 4,797 videos distribuidos en cuatro clases. Para cuantificar el desbalance se calculó el ratio de desbalance (IR) de cada clase respecto a la clase mayoritaria (*irrelevant*):

$$\mathrm{IR}_c = \frac{n_{\text{máx}}}{n_c} \tag{2}$$

donde n_c es el número de videos de la clase c y $n_{\text{máx}}$ el de la clase mayoritaria. Los resultados se muestran en la Tabla I.

Tabla I
Distribución de clases y ratio de desbalance

Clase	Cantidad	%	IR
Irrelevant	1,936	40.4	1.00×
Suitable	1,513	31.5	1.28×
Disturbing	929	19.4	2.08×
Restricted	419	8.7	4.62×
Total	**4,797**	**100**	

La clase mayoritaria es *irrelevant* (40.4 %), seguida de *suitable* (31.5 %). Las clases de interés para la detección (*disturbing* y *restricted*) representan el 28.1 % del dataset, y *restricted* es 4.6 veces más pequeña que la clase mayoritaria. Este desbalance se trata con pesos de clase balanceados (Sección V-C).

Tabla II
ESTADÍSTICAS POR CLASE

Medida	Dist.	Irrel.	Restr.	Suit.
Vistas (mediana)	39,144	10,436	1,348,394	407,330
Likes (mediana)	202	87	5,130	1,342
Coment. (mediana)	27	14	531	69.5
Duración s (med.)	359	264	350	443.5
Título, caract. (media)	58.98	46.80	44.79	61.88
Título, palabras	10.04	8.12	7.79	10.91

II-D. Valores faltantes y calidad de los datos

Respecto a los valores faltantes, `tags` es la más afectada (883 videos, 18.4 %), seguida de `description` (506, 10.5 %), `comment_count` (228, 4.8 %), y `like_count` y `dislike_count` (128 cada una, 2.7 %). `view_count` tiene 3 valores faltantes, y `duration_seconds` y `definition` tienen 1 cada una. `title` y `category_id` no presentan valores faltantes. La columna `prediction` está vacía en todo el ground truth (Sección II-J). Además, 11 videos tienen 0 vistas y 10 tienen duración igual a 0, lo que obliga a tratar la división por cero al construir razones de interacción (Sección III). No se encontraron videos duplicados (mismo `video_id`): los 4,797 registros son únicos.

II-E. Estadísticas descriptivas

Las métricas de interacción del ground truth presentan una asimetría muy fuerte: la media de `view_count` (6,142,716.96) es muy superior a su mediana (90,093.5) y su máximo supera los 1,664 millones; lo mismo ocurre con likes (media 26,878, mediana 502), dislikes (3,719 y 53) y comentarios (2,378 y 49). La duración promedio es de 752.06 s (12.5 min), mientras que la mediana es de 345.5 s (5.8 min). Los máximos muestran outliers significativos, sobre todo en visualizaciones y duración (Sección II-G).

II-F. Análisis por clase

La Tabla II compara las variables numéricas y de título entre clases. *Suitable* presenta la mayor media de vistas (10,761,959.60), mientras que *restricted* presenta la mayor mediana de vistas y la mayor media de comentarios. Las medias están fuertemente afectadas por outliers, por lo que las medianas ofrecen una comparación más robusta. Por ello, no es correcto atribuir el mayor nivel de interacción a la clase *disturbing*.

Duración. Suitable tiene la mayor duración media (872.00 s) y mediana (443.5 s). Las medianas se sitúan entre 264 y 443.5 s (4.4 a 7.4 min), y la variabilidad es especialmente alta en *irrelevant* y *suitable* por la presencia de videos muy largos.

Categorías y definición. El dataset abarca 17 categorías de YouTube (Fig. 1; los nombres provienen de la YouTube Data API [6]). Las tres más frecuentes son *Entertainment*, *People & Blogs* y *Film & Animation*, y algunas categorías predominan en ciertas clases. Respecto a la calidad, 3,748 videos (78.1 %) están en HD y 1,048 (21.8 %) en SD. La asociación entre la definición y la clase es estadísticamente significativa ($\chi^2 = 23.30$, $p = 3.5\times10^{-5}$), pero muy débil (V de Cramér $= 0.07$),

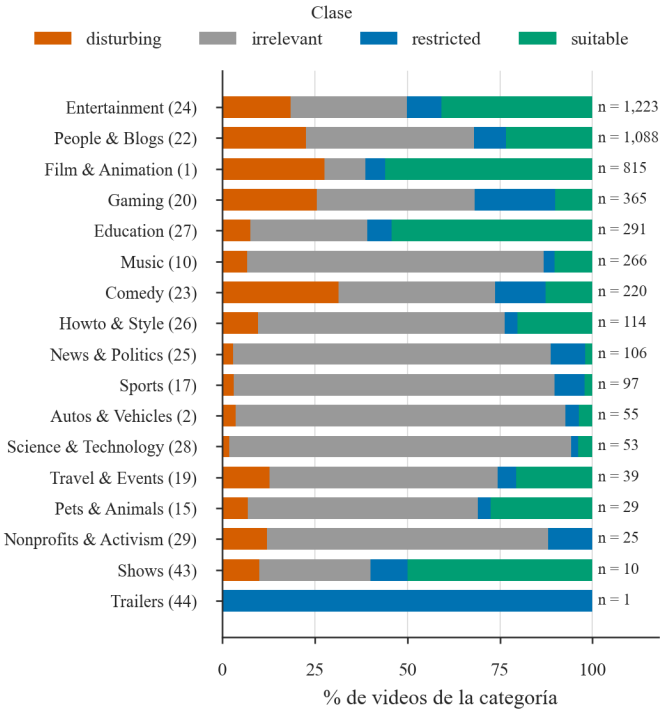


Figura 1. Composición por clase de cada categoría de YouTube, ordenadas por número de videos (n; entre paréntesis, el ID de categoría). Los porcentajes de las categorías con pocos videos son poco fiables.

por lo que la calidad del video no parece estar directamente relacionada con la clasificación de contenido.

Títulos. Los títulos tienen en promedio 53.74 caracteres y 9.34 palabras. Los títulos de *suitable* tienen la mayor longitud media (61.88 caracteres) y cantidad media de palabras (10.91), seguidos por los de *disturbing*, mientras que *restricted* presenta los títulos más cortos en promedio (Tabla II). La longitud del título podría ser una característica discriminante.

Etiquetas (tags). 3,914 videos tienen tags y 883 (18.4 %) no tienen. Esos registros contienen 3,705 listas de tags distintas; al separar cada lista por `|` (eliminando espacios y cadenas vacías) se obtienen 40,096 tags individuales únicos y 73,640 asignaciones en total (18.8 tags por video en promedio). Al normalizar a minúsculas se consolidan 36,750 tags únicos, y la Tabla III usa esta versión, contando cada tag una sola vez por video. Al cruzar los tags individuales más frecuentes con la clase se observan asociaciones marcadas: el 74.6 % de los videos con el tag *spiderman* son *disturbing*, frente al 19.4 % en todo el ground truth, mientras que el 80.1 % de los videos con *for kids* son *suitable*, frente al 31.5 %. Los tags *spiderman*, *superhero*, *elsa* y *frozen* se distribuyen en 181, 133, 171 y 169 canales distintos, respectivamente, y el canal con más videos de cada uno aporta menos del 4 % del total, por lo que su asociación con *disturbing* no depende de un solo canal. En cambio, para *kids* (412 videos en 270 canales) y *children* (215 videos en 129 canales), un único canal, el mismo que aparece con clases mixtas en la Sección II-J, aporta el 7.3 % y el 14.4 % de los videos, respectivamente. Estas asociaciones son

Tabla III
TAGS INDIVIDUALES FRECUENTES (EN MINÚSCULAS): % DE VIDEOS POR CLASE

Tag	Videos	Dist.	Irrel.	Restr.	Suit.
spiderman	209	74.6	4.3	1.9	19.1
superhero	156	74.4	6.4	0.6	18.6
elsa	200	60.0	6.0	3.0	31.0
frozen	194	57.7	5.7	2.6	34.0
funny	400	39.5	19.0	6.5	35.0
kids	412	31.1	4.6	1.2	63.1
children	215	20.9	7.9	0.0	71.2
cartoon	299	24.7	2.7	0.3	72.2
for kids	136	12.5	4.4	2.9	80.1
Ground truth	4,797	19.4	40.4	8.7	31.5

Tabla IV
OUTLIERS DETECTADOS POR EL MÉTODO IQR

	Escala original		Escala log	
Variable	**N.°**	**%**	**N.°**	**%**
`view_count`	802	16.73	0	0.00
`like_count`	730	15.64	0	0.00
`dislike_count`	791	16.94	0	0.00
`comment_count`	721	15.78	0	0.00
`duration_seconds`	385	8.03	173	3.61

descriptivas; en entrenamiento, *spiderman*, *superhero* y *elsa* aparecen entre los tags más asociados a *disturbing* (Tabla V).

II-G. Detección de outliers

Se aplicó el método del rango intercuartílico (IQR) sobre las cinco variables numéricas, tanto en su escala original como sobre una transformación logarítmica $\log(1+x)$ (Tabla IV). Esta segunda versión es necesaria porque, dada la fuerte asimetría de las métricas de interacción, el IQR en escala original marca como outlier a una fracción muy grande de las observaciones (entre 15.6 % y 16.9 %), lo cual no es informativo.

En escala logarítmica, el número de outliers en las cuatro variables de interacción desciende a 0, lo que muestra que las observaciones siguen una distribución log-normal coherente y que no constituyen errores ni datos anómalos. Únicamente `duration_seconds` retiene 173 outliers (3.61 %), correspondientes a videos notablemente cortos o largos. Al cruzar los valores extremos de vistas (>4.4M) y likes (>25.3K) con la clase, se observa que están repartidos entre todas las clases (en vistas: 379 *suitable*, 175 *irrelevant*, 132 *restricted* y 116 *disturbing*). Por ello, corresponden a contenido popular legítimo dentro de cada categoría y no deben descartarse, sino transformarse mediante $\log(1+x)$ (Sección III).

II-H. Relaciones entre variables

Se analizó la correlación entre las variables numéricas (Pearson en escala original y logarítmica, y Spearman) para identificar redundancia y posibles problemas de multicolinealidad (la Fig. 2 muestra la matriz de Spearman). Las métricas de interacción presentan una correlación excepcionalmente alta entre sí: `view_count` y `dislike_count` (Spearman 0.966, Pearson log 0.940), `view_count` y `like_count`

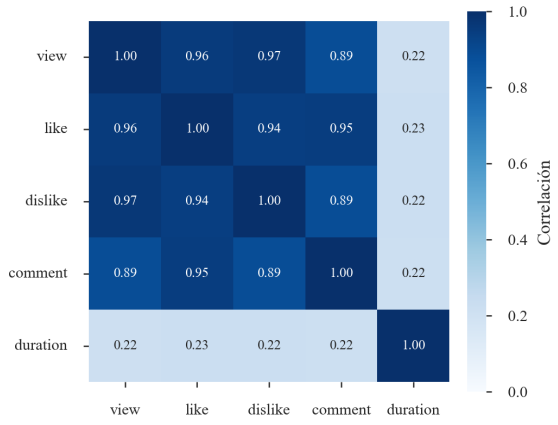


Figura 2. Correlación de Spearman entre las variables numéricas (los valores de Pearson en escala $\log(1+x)$ se reportan en el texto).

(Spearman 0.956, Pearson log 0.955), y `like_count` y `comment_count` (Spearman 0.948, Pearson log 0.947). Esta colinealidad casi unitaria desaconseja emplear los cuatro conteos como variables directas simultáneas; en su lugar, se deben formular razones normalizadas (likes/vistas, comentarios/vistas). Por su parte, `duration_seconds` mantiene correlaciones bajas con las variables de interacción (Pearson log entre 0.228 y 0.241, Spearman entre 0.217 y 0.225), por lo que provee una señal complementaria e independiente.

Adicionalmente, se aplicó la prueba de Kruskal-Wallis para evaluar si la distribución de cada variable numérica difiere de forma estadísticamente significativa entre las cuatro clases. Las cinco variables resultaron significativas, todas con $p < 10^{-27}$ (desde $H = 129.9$ en `duration_seconds` hasta $H = 523.9$ en `view_count`). No obstante, dado el tamaño muestral (∼4,800 observaciones), diferencias distributivas pequeñas pueden alcanzar significancia con facilidad; por ello, este resultado funciona como un filtro preliminar positivo (ninguna variable se descarta a priori), y su capacidad predictiva se evaluó después con SHAP sobre el modelo final (Sección VI-C).

II-I. Conjuntos adicionales

Un primer análisis de las 1,000 primeras líneas de cada conjunto mostró que en ellas predominan videos del ground truth (78.0 % en `elsagate_related` y 49.0 % en `popular_videos`), por lo que se revisó el corpus consolidado completo (844,702 videos únicos), en el que cada video del ground truth aparece una sola vez y queda separado de los conjuntos adicionales. Fuera del ground truth, el clasificador original predijo como inapropiados 1,260 de 230,873 videos de `elsagate_related` (0.55 %), 586 de 137,043 de `other_child_related` (0.43 %), 3,388 de 462,382 de `random_videos` (0.73 %) y ninguno de los 9,607 de `popular_videos`. Como el consolidado asigna un único conjunto de origen a cada video, un video presente en varios conjuntos se cuenta solo en uno.

II-J. Posible fuga de datos (data leakage)

Se revisaron cuatro fuentes potenciales de fuga de datos relevantes para el diseño experimental:

1. **Columnas que codifican la etiqueta o la predicción original.** `prediction` e `is_ground_truth` son generadas por el clasificador automático de los autores del dataset y por el proceso de anotación, respectivamente. No son información disponible de forma independiente para un video nuevo, por lo que no deben usarse como características. En el ground truth, `prediction` contiene 100 % de valores nulos (4,797 registros) e `is_ground_truth` toma el valor constante 1.
2. **Duplicados dentro del ground truth.** Se constató que existen 0 videos duplicados (mismo `video_id`); los 4,797 registros son videos únicos. De existir duplicados, un mismo video repetido en entrenamiento y validación inflaría artificialmente el desempeño.
3. **Solapamiento entre ground truth y conjuntos adicionales.** Como el ground truth se usa para entrenar y los conjuntos adicionales para comprobación de consistencia, un video presente en ambos dejaría de ser una prueba genuina de generalización. En las 1,000 primeras líneas analizadas, los videos en común son 780 (78.0 %) en `elsagate_related`, 70 (7.0 %) en `other_child_related`, 34 (3.4 %) en `random_videos` y 490 (49.0 %) en `popular_videos`. Estos videos se excluyen de la comprobación (Sección VI-E).
4. **Concentración de videos por canal.** El ground truth contiene 3,818 canales únicos (por `channel_id`), de los cuales 418 tienen más de un video (máximo de 33 videos para un canal). Entre los 13 canales con 12 o más videos (seis empatan con exactamente 12), 11 concentran el 100 % en *suitable*, uno tiene el 91.7 % en *suitable* (11 *suitable* y 1 *disturbing*) y solo uno (33 videos) presenta mezcla de clases (20 *disturbing* y 13 *suitable*). Esto implica riesgo de que el modelo memorice características propias del canal, y de fuga de datos si videos del mismo canal quedan repartidos entre entrenamiento y validación o prueba. Por ello, tanto el conjunto de prueba como la validación cruzada se agrupan por canal y se estratifican por clase con `StratifiedGroupKFold` (Sección V-A).

II-K. Limitaciones

Los conjuntos adicionales se analizaron solo con las primeras 1,000 líneas de un archivo, que no son muestras aleatorias y no representan la distribución de los conjuntos completos. Los datos corresponden a un periodo específico (la mayoría de 2014 a 2018, con videos hasta 2019) y YouTube ha cambiado significativamente desde entonces, por lo que los patrones pueden haber evolucionado. Además, las etiquetas manuales pueden contener sesgos subjetivos de los anotadores humanos.

III. Preprocesamiento e Ingeniería de Características

El script `data_processing/preprocessing.py` implementa el preprocesamiento y genera el archivo `dataset_features_v1.csv`, con los 4,797 videos del ground truth, 16 características, la etiqueta y tres columnas de metadatos (`video_id`, `channel_id` y `split`) que no se usan como características. Para evitar fuga de datos, todos los valores que se aprenden de los datos (medianas, modas y vocabularios) se ajustan solo con el conjunto de entrenamiento.

III-A. Partición previa

Antes de transformar los datos se reservó el conjunto de prueba con `StratifiedGroupKFold` (5 particiones, semilla 42), estratificando por clase y agrupando por `channel_id`, y se tomó la primera partición como prueba: 3,842 videos de entrenamiento y 955 de prueba (19.9 %), sin canales en común (Sección II-J). Así, las estadísticas de imputación no incorporan información del conjunto de prueba.

III-B. Transformaciones aplicadas

- **Valores faltantes numéricos:** `like_count`, `dislike_count` (128), `comment_count` (228), `view_count` (3) y `duration_seconds` (1) se imputan con la mediana de entrenamiento, robusta frente a la fuerte asimetría observada (Sección II-G).
- **Valores faltantes categóricos:** `definition`, `caption` y `licensed_content` (1 faltante cada una) se imputan con la moda de entrenamiento.
- **Texto faltante:** la ausencia de descripción (506) o de tags (883) se representa como texto vacío, sin inventar contenido. Los tags se normalizan a minúsculas y se separan por `|`, como en el análisis de la Sección II-B.
- **Transformación logarítmica:** los cuatro conteos de interacción se transforman con $\log(1+x)$, que elimina los outliers detectados por el IQR (Tabla IV) sin descartar videos.
- **Codificación y escalamiento:** `category_id`, `definition`, `caption` y `licensed_content` se codifican con one-hot (las categorías con menos de 5 videos se agrupan), y las variables numéricas se estandarizan.

III-C. Características derivadas

- **Razones de interacción:** likes/vistas y comentarios/vistas, que sustituyen el uso conjunto de conteos casi colineales (Sección II-H). Si faltan los conteos o las vistas son 0 (11 videos), la razón queda indefinida y se imputa con la mediana de entrenamiento.
- **Longitud del título:** número de caracteres y de palabras. Sus medias reproducen las de la Tabla II (alrededor de 60 caracteres en *suitable* y *disturbing* frente a 45 en *irrelevant* y *restricted*).
- **Representación del texto:** TF-IDF con frecuencia sublineal y sin acentos sobre el título y la descripción (unigramas y bigramas) y sobre los tags, tratando cada

Tabla V
TAGS MÁS ASOCIADOS A CADA CLASE EN ENTRENAMIENTO (χ^2)

Clase	Tags
Disturbing	spiderman, superhero, mlg, spidey, spider-man, joker, elsa
Irrelevant	srbija, pop, 2016, rap, comedian, sports
Restricted	sexy, sex, prankzone tv, playstation 4, hot, hypnosis
Suitable	tom and jerry, cartoon, kids, animation, animated cartoon

tag completo como un token (por ejemplo, *for kids*). Ajustado con el conjunto de entrenamiento genera 4,985 columnas para el título, 27,344 para la descripción y 5,927 para los tags. Para los modelos de árboles, este bloque puede reducirse con `TruncatedSVD`.

El texto se vectoriza dentro de un `Pipeline` de scikit-learn, de modo que en la validación cruzada el vocabulario y los pesos IDF se ajustan solo con las particiones de entrenamiento. La Tabla V muestra los tags con mayor asociación a cada clase en entrenamiento (prueba χ^2, una clase contra el resto). Coinciden con los hallazgos del EDA, pero algunos términos corresponden a series o canales concretos (por ejemplo, *tom and jerry* o *prankzone tv*), lo que confirma la necesidad de validar agrupando por canal.

III-D. Variables excluidas

No se usan como características `prediction` e `is_ground_truth` (codifican el proceso de clasificación o de anotación), `source_dataset` (constante), `favorite_count` (siempre 0), `published_at` y `duration_iso` (redundante con `duration_seconds`), ni los identificadores `video_id`, `channel_id` y `channel_title`, para que el modelo no memorice canales (Sección II-J); `channel_id` se conserva solo para agrupar la partición. Las mismas transformaciones, con los valores de imputación de entrenamiento, se aplican a los conjuntos adicionales.

IV. METODOLOGÍA Y MODELOS

Todos los modelos se implementaron con scikit-learn [7] y LightGBM [8] como un `Pipeline` que contiene el preprocesamiento de la Sección III y el clasificador, y se evaluaron con las mismas particiones agrupadas por canal (Sección V-A). Se usan tres vistas de las características: *texto* (TF-IDF de título, descripción y tags), *metadatos* (duración, interacción, razones, longitud del título y variables categóricas) y *combinada* (ambas concatenadas).

IV-A. Modelos baseline

- **Dummy (clase mayoritaria):** siempre predice *irrelevant*. Es el piso de referencia de H1: cualquier modelo útil debe superarlo con claridad en F1 macro.
- **Regresión logística + TF-IDF:** modelo lineal estándar para clasificación de texto disperso y de alta dimensión, con pesos de clase balanceados y $C = 1$.
- **Naive Bayes multinomial + TF-IDF:** alternativa probabilística muy rápida, habitual como baseline de texto ($\alpha = 0.1$).

Los dos baselines de texto miden cuánto se puede lograr solo con el título, la descripción y los tags, sin las variables de interacción.

IV-B. Modelos comparados

- **Random Forest y LightGBM sobre metadatos:** modelos de árboles adecuados para variables tabulares con escalas y asimetrías distintas y con interacciones no lineales (por ejemplo, entre duración y vistas). Random Forest usa 500 árboles; LightGBM, *gradient boosting* con 400 árboles y `learning_rate` de 0.05.
- **LightGBM combinado:** el bloque TF-IDF (38,256 columnas dispersas) se reduce a 200 componentes con `TruncatedSVD`, porque los árboles no aprovechan bien matrices tan dispersas, y se concatena con los metadatos.
- **Regresión logística combinada:** usa el TF-IDF completo junto con los metadatos estandarizados. Mantiene toda la información del texto y permite interpretar cada coeficiente, lo que es importante para la transparencia (Sección VII-C).

Además, un *ablation study* entrena el mismo LightGBM con solo texto, solo metadatos y ambos, para medir el aporte de cada fuente de información. Todos los modelos usan `class_weight="balanced"` (Sección V-C).

IV-C. Selección de hiperparámetros

Los dos mejores modelos combinados se ajustaron con `RandomizedSearchCV` (20 combinaciones, semilla 42) sobre las mismas cinco particiones agrupadas del conjunto de entrenamiento, con el F1 macro medio como criterio:

- **Regresión logística:** $C \in [0.05, 20]$ con distribución log-uniforme, ya que la regularización actúa en escala multiplicativa. Mejor valor: $C = 1.16$.
- **LightGBM:** número de árboles $\in [200, 1000]$, `learning_rate` $\in [0.01, 0.2]$, `num_leaves` $\in [8, 64]$, `min_child_samples` $\in [5, 60]$, `colsample_bytree` $\in [0.4, 1.0]$ y `reg_lambda` $\in [0.001, 10]$. La mejor combinación (227 árboles, 14 hojas y $\lambda = 2.5$) favorece modelos más simples y regularizados.

La regresión logística ajustada obtuvo un F1 macro de 0.710 ± 0.024 frente a 0.698 ± 0.027 de LightGBM, y un recall en *restricted* de 0.558 frente a 0.478, por lo que fue elegida como modelo final. Como ambos usan las mismas particiones, se compararon también fold a fold: la regresión logística supera a LightGBM en 4 de 5 particiones en F1 macro (diferencia media $+0.012 \pm 0.008$, t pareada con $p = 0.03$) y en las 5 en recall de *restricted* ($+0.080$, $p = 0.01$); con cinco particiones que comparten datos de entrenamiento, estos p-valores son solo orientativos. Se reentrenó con todo el conjunto de entrenamiento y se evaluó una sola vez en prueba (Sección VI-B).

Tabla VI
PARTICIONES AGRUPADAS POR CANAL: VIDEOS, CANALES Y % POR CLASE

Partición	Videos	Canales	Dist.	Irrel.	Restr.	Suit.
Fold 0	745	608	17.6	40.5	8.9	33.0
Fold 1	747	608	19.3	42.6	11.0	27.2
Fold 2	784	614	22.2	41.7	6.8	29.3
Fold 3	768	614	19.7	38.0	8.9	33.5
Fold 4	798	608	17.2	41.9	8.8	32.2
Prueba	955	766	20.1	38.0	8.4	33.5
Ground truth	4,797	3,818	19.4	40.4	8.7	31.5

V. DISEÑO EXPERIMENTAL Y EVALUACIÓN

V-A. Estrategia de validación

El análisis de la Sección II-J mostró que los videos de un mismo canal comparten clase con frecuencia (11 de los 13 canales con 12 o más videos son 100 % *suitable*) y que algunos términos del texto identifican canales o series concretas (Tabla V). Si videos de un mismo canal quedaran a ambos lados de la partición, el modelo podría acertar por reconocer el canal y no por el contenido. Por ello, toda la partición se agrupa por `channel_id` y se estratifica por clase con `StratifiedGroupKFold` (scikit-learn 1.7.2, semilla 42):

- **Conjunto de prueba:** la primera de cinco particiones del ground truth (955 videos, 19.9 %), reservada y usada una sola vez para la evaluación final.
- **Validación cruzada:** cinco particiones construidas solo sobre los 3,842 videos de entrenamiento con el mismo criterio. Todos los modelos usan exactamente las mismas particiones (`modeling/folds_v1.csv`), lo que hace comparables sus resultados y permite usarlas también para ajustar hiperparámetros.

La Tabla VI muestra que ningún canal aparece en más de una partición y que la proporción de cada clase se aleja como máximo 4.4 puntos porcentuales de la del ground truth completo. Todas las transformaciones que aprenden de los datos (imputación, TF-IDF, escalamiento y reducción de dimensión) se aplican dentro de un `Pipeline`, por lo que en cada partición se ajustan solo con los datos de entrenamiento.

Para cuantificar el riesgo, se evaluó un mismo modelo de referencia (TF-IDF sobre título, tags y descripción con regresión logística balanceada) con validación cruzada aleatoria (`StratifiedKFold`) y con las particiones agrupadas por canal, ambas sobre el conjunto de entrenamiento (Tabla VII). La validación aleatoria da un F1 macro 0.020 mayor, y lo mismo ocurre con el recall macro y la exactitud. La diferencia es moderada y está dentro de la variabilidad entre particiones, pero tiene el sentido esperado: con una partición aleatoria, parte del desempeño se debe a reconocer canales ya vistos. Por eso todos los resultados de este trabajo se reportan con la validación agrupada, que es la más cercana al uso real del modelo sobre canales nuevos.

V-B. Métricas de evaluación

Dado el desbalance de clases (IR hasta $4.62\times$, Tabla I), la exactitud (accuracy) no es una métrica adecuada: un clasificador trivial que siempre prediga *irrelevant* obtendría 40.4 % sin detectar ningún video problemático. Por ello se adoptan las siguientes métricas principales:

- **F1 macro:** media no ponderada del F1 de cada clase. Penaliza por igual el bajo desempeño en cualquier clase, incluidas las minoritarias.
- **Recall por clase:** especialmente en *disturbing* y *restricted*, donde un falso negativo tiene consecuencias directas para la seguridad infantil.
- **AUC-ROC** (one-vs-rest): mide la capacidad discriminativa independientemente del umbral de decisión.
- **Average Precision (AP):** área bajo la curva Precision-Recall, más informativa que AUC-ROC cuando las clases positivas son minoritarias.
- **Matriz de confusión:** para identificar patrones de error entre clases adyacentes.

Tabla VII
VALIDACIÓN ALEATORIA VS. AGRUPADA POR CANAL (MEDIA $\pm$ DESV. EST., 5 PARTICIONES)

Validación	F1 macro	Recall macro	Exactitud
Aleatoria	0.699 ± 0.020	0.681 ± 0.020	0.766 ± 0.014
Agrupada por canal	0.678 ± 0.028	0.661 ± 0.025	0.751 ± 0.018

V-C. Manejo del desbalance de clases

Se adoptó `class_weight="balanced"` en todos los modelos, que ajusta los pesos de cada clase inversamente proporcional a su frecuencia. Esta estrategia evita la generación de datos sintéticos (SMOTE), que podría introducir interpolaciones irrealistas en el espacio TF-IDF de alta dimensión. La alternativa SMOTE se descartó porque el bloque de texto genera matrices dispersas de hasta 38,288 columnas, donde las interpolaciones entre vectores no tienen interpretación semántica clara.

VI. RESULTADOS Y ANÁLISIS

VI-A. Comparación de modelos

La Tabla VIII compara todos los modelos evaluados con validación cruzada de 5 particiones agrupadas por canal (solo sobre train, 3,842 videos). El modelo combinado de regresión logística (TF-IDF + metadatos) obtiene el mejor F1 macro y el mayor recall en *restricted*, la clase más difícil. El ablation study muestra que el texto aporta más que los metadatos solos, y que la combinación supera a cualquiera de las dos fuentes por separado. La tabla usa los hiperparámetros iniciales; la versión ajustada ($C = 1.16$, Sección IV-C) obtiene el mismo F1 macro (0.710 ± 0.024).

VI-B. Modelo final en el conjunto de prueba

El modelo seleccionado (LogReg combinado, `C=1.16`, ajustado con `RandomizedSearchCV` sobre train) se evaluó *una sola vez* sobre los 955 videos de prueba, cuyos canales no aparecen en entrenamiento. La Tabla IX resume los resultados.

La Fig. 3 muestra las curvas ROC y la Fig. 4 las curvas Precision-Recall para cada clase. *Restricted* concentra el AUC y AP más bajos (0.878 y 0.483 respectivamente), lo que

Tabla VIII
COMPARACIÓN DE MODELOS — VALIDACIÓN CRUZADA AGRUPADA POR CANAL (MEDIA ± DESV. EST., 5 FOLDS)

Modelo	F1 macro	Rec. disturb.	Rec. restr.
Dummy (mayoritaria)	0.145 ± 0.004	0.000	0.000
Naive Bayes + TF-IDF	0.659 ± 0.033	0.670	0.254
LogReg + TF-IDF	0.672 ± 0.025	0.637	0.359
RF (metadatos)	0.575 ± 0.027	0.457	0.323
LightGBM (metadatos)	0.580 ± 0.020	0.496	0.326
LightGBM (texto solo)	0.625 ± 0.002	0.609	0.157
LightGBM combinado	0.682 ± 0.020	0.621	0.331
LogReg combinado (C=1)	**0.710 ± 0.023**	**0.664**	**0.566**

Tabla IX
MÉTRICAS DEL MODELO FINAL EN EL CONJUNTO DE PRUEBA (955 VIDEOS)

Clase	Prec.	Recall	F1	AUC	AP
Disturbing	0.801	0.714	0.755	0.929	0.848
Irrelevant	0.794	0.837	0.815	0.921	0.873
Restricted	0.500	0.550	0.524	0.878	0.483
Suitable	0.815	0.797	0.806	0.929	0.885
Macro	**0.727**	**0.724**	**0.725**	**0.914**	**0.772**

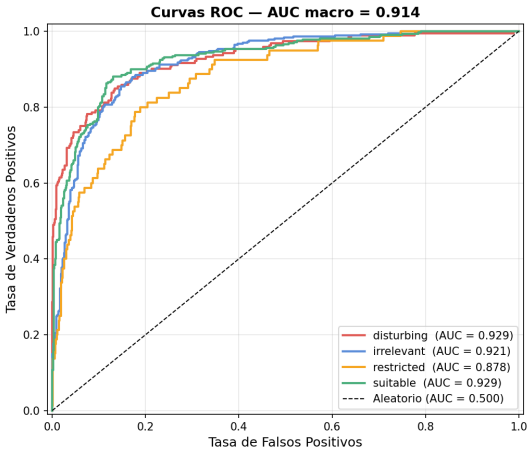


Figura 3. Curvas ROC one-vs-rest. AUC macro = 0.914.

refleja la escasez de ejemplos (339 videos en entrenamiento, IR = 4.62×) y la superposición con *irrelevant* en el espacio de metadatos. La Fig. 5 presenta la matriz de confusión: los principales errores ocurren entre *suitable* ↔ *disturbing* (29 FN y 14 FP) y entre *irrelevant* ↔ *restricted* (22 FN y 24 FP).

VI-C. Importancia de características (SHAP)

Se calcularon valores SHAP [9] con `LinearExplainer` (exacto para regresión logística) sobre los 955 videos de prueba, con la media de entrenamiento como referencia. La Fig. 6 muestra la importancia global media |SHAP|: de forma individual, las características más influyentes son los conteos de interacción (likes, vistas, dislikes y comentarios), seguidos de la categoría y `licensed_content`; los primeros términos de texto (*peppa*, *pig*, *elsa*) aparecen más abajo. Sin embargo, la importancia del texto se reparte entre 38,256 columnas TF-IDF. Sumada por bloque, el texto aporta el 65.1 % de la importancia en *disturbing* y el 55.1 % en *suitable*,

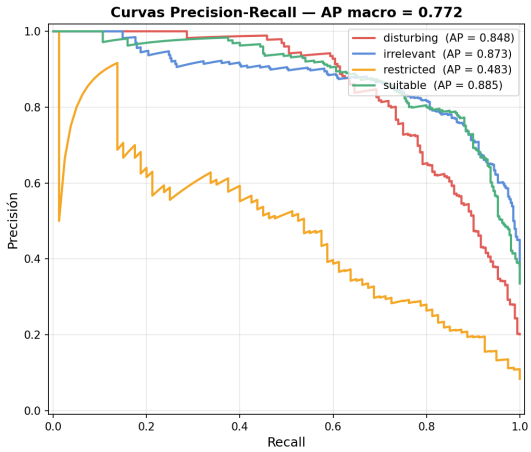


Figura 4. Curvas Precision-Recall. AP macro = 0.772. La clase *restricted* muestra la mayor caída por su bajo soporte (80 videos en test).

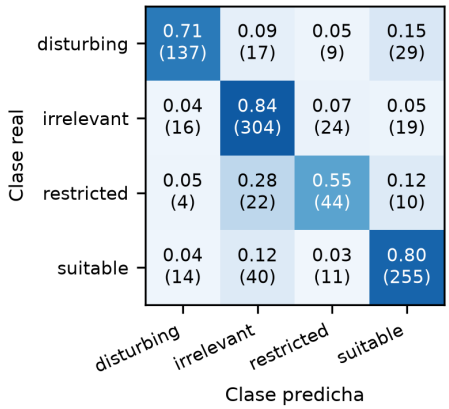


Figura 5. Matriz de confusión sobre el conjunto de prueba, normalizada por fila (recall por celda); entre paréntesis, el número de videos.

mientras que en *restricted* (40.5 %) e *irrelevant* (41.7 %) pesan más los metadatos. Esto es consistente con el ablation study, donde el texto solo (F1 0.625) supera a los metadatos solos (0.580) y la combinación supera a ambos.

Por clase, la Tabla X resume las cinco features de mayor importancia para *disturbing* y *restricted*. Para *disturbing*, junto a los likes, la duración y la categoría aparecen términos del título asociados a personajes infantiles (*peppa*, *pig*, *elsa*), coherentes con la Tabla V. Para *restricted*, los conteos de interacción dominan sobre el texto, ya que el vocabulario explícito es poco frecuente en el dataset.

VI-D. Análisis de errores

Se analizaron los falsos negativos de las dos clases críticas sobre los 955 videos de prueba:

Disturbing (55 FN, 28.6 % no detectados): la mayoría se predice como *suitable* (29) o *irrelevant* (17). Los títulos de los falsos negativos son genéricos —sin señales textuales explícitas de contenido inapropiado—, como *"JooJooTV 4K | THE LITTERER | Kids Cartoons | Best Cartoons For Kids 2019"* (predicho como *suitable* con 95 % de confianza) o

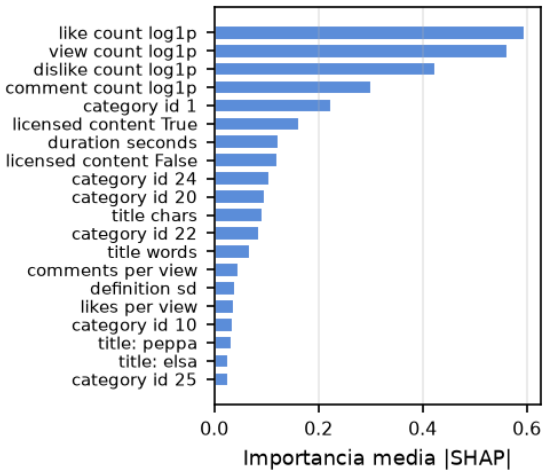


Figura 6. Importancia SHAP global (top 20 features, media |SHAP| sobre todas las clases).

Tabla X
TOP 5 FEATURES SHAP PARA LAS CLASES CRÍTICAS

Clase	Feature	|SHAP|
Disturbing	like_count_log1p	0.272
	duration_seconds	0.247
	category_id (1)	0.219
	licensed_content	0.151
	title_chars	0.149
Restricted	like_count_log1p	1.194
	dislike_count_log1p	0.809
	view_count_log1p	0.589
	comment_count_log1p	0.284
	licensed_content	0.178

"Scary Shark | Nursery Rhymes | Scary Videos For Kids" (predicho como *suitable* con 92 %). Estos casos ilustran el límite fundamental del enfoque basado en texto: un creador malintencionado puede usar vocabulario infantil legítimo para enmascarar contenido perturbador.

Restricted (36 FN, 45.0 % no detectados): se predice principalmente como *irrelevant* (22) o *suitable* (10). Los títulos mezclando personajes animados con contenido adulto —*"Spider Man vs Elsa | Frozen Elsa and Spider Man GTA 5"*— confunden el modelo porque comparten vocabulario con *disturbing* o con *suitable*. Esto está alineado con la Consideración ética de la Sección VII-C: estos falsos negativos representan el mayor riesgo del sistema.

La confusión entre *irrelevant* y *restricted* (24 FP en restricted, 22 FN de restricted hacia irrelevant) sugiere que el texto no siempre distingue contenido adulto disfrazado. Los metadatos de engagement ayudan —*restricted* tiene medianas de vistas y likes muy superiores (Tabla II)— pero no eliminan la ambigüedad.

VI-E. Consistencia en conjuntos adicionales

El modelo final se aplicó a los 839,905 videos de los conjuntos adicionales que no forman parte del ground truth (`modeling/additional_inference.py`), con las mismas transformaciones y los valores de imputación de entrenamiento. Para comparar con la predicción binaria del clasificador original [4], un video se considera *inapropiado* si el modelo predice *disturbing* o *restricted*. Como no hay etiquetas humanas, la Tabla XI mide consistencia entre ambos clasificadores y no eficacia.

Tabla XI
VIDEOS PREDICHOS COMO INAPROPIADOS FUERA DEL GROUND TRUTH: MODELO FINAL VS. CLASIFICADOR ORIGINAL

Conjunto	Videos	Modelo	Original	Acuerdo	Kappa
Elsagate	230,873	21.78 %	0.55 %	77.87 %	−0.002
Other child	137,043	11.92 %	0.43 %	87.67 %	−0.007
Random	462,382	6.74 %	0.73 %	92.62 %	0.000
Popular	9,607	12.00 %	0.00 %	88.00 %	0.000

PI2 (`elsagate_related`): el modelo predice como inapropiados el 21.78 % de los videos (8.59 % *disturbing* y 13.19 % *restricted*), unas 40 veces más que el clasificador original (0.55 %). Por tanto, **H2 no se cumple**. El acuerdo de 77.87 % se debe casi por completo a los videos que ambos consideran apropiados: el kappa de Cohen [10] es prácticamente 0, y de los 1,260 videos que marcó el clasificador original, el modelo coincide solo en 227 (18.0 %).

PI3 (`other_child_related`, `random`, `popular`): las proporciones del modelo (11.92 %, 6.74 % y 12.00 %) son también un orden de magnitud mayores que las del clasificador original, por lo que **H3 tampoco se cumple**. Sí se conserva el orden de riesgo esperado: la proporción es máxima en `elsagate_related`, y la clase *disturbing* (la más ligada al fenómeno Elsagate) cae de 8.59 % en ese conjunto a 1.20 % en `random`.

Revisión cualitativa de los desacuerdos: el exceso de alertas proviene sobre todo de *restricted*, que el modelo asigna a contenido general para adultos que no se dirige a niños, como música (*"When I Was Your Man - Bruno Mars lyric"*), deportes (*"Super Bowl XLIX: Patriots vs. Seahawks highlights"*), lucha libre o videos en idiomas poco presentes en el ground truth. Estos videos tienen conteos de interacción altos, que son precisamente las características con mayor peso SHAP para *restricted* (Tabla X). En el ground truth casi todo el contenido es infantil o lo parece, por lo que el modelo no aprendió a separar "contenido para adultos inofensivo" de "contenido restringido"; además, `class_weight="balanced"` favorece las clases minoritarias. A la inversa, varias alertas del clasificador original que el modelo no reproduce parecen errores de ese clasificador (por ejemplo, un episodio de Peppa Pig en ruso, un video eliminado o videos de fútbol). Los casos en que ambos coinciden sí incluyen ejemplos típicos de Elsagate, como *"Minecraft SPONGEBOB.EXE - JUMPING INTO SPONGEBOBS NIGHTMARE IS REALLY SCARY!!"*.

En conjunto, el modelo se desplaza hacia más alertas cuando cambia la distribución de los datos. Es útil para priorizar la revisión humana de contenido infantil, pero no debería aplicarse sin recalibrar sobre plataformas abiertas, donde la mayoría del contenido no es infantil.

VII. Discusión y Limitaciones

VII-A. Interpretación de resultados

Por qué ganó la regresión logística combinada. Con 3,842 videos de entrenamiento y más de 38 mil columnas de texto, el problema está en el régimen de alta dimensión y pocos ejemplos, donde los modelos lineales regularizados suelen funcionar mejor que los árboles. LightGBM necesita reducir el texto con SVD, y esa reducción conserva las direcciones de mayor varianza (el vocabulario frecuente), pero pierde términos raros y muy discriminativos. El efecto se ve en *restricted*, cuyo vocabulario (*sexy*, *hypnosis*, Tabla V) es escaso: con solo texto, el recall de esta clase es 0.157 con LightGBM y SVD frente a 0.359 con regresión logística sobre el TF-IDF completo (Tabla VIII). Al combinar texto y metadatos, la diferencia persiste (0.331 frente a 0.566).

Las dos fuentes de información son complementarias. El ablation study y el análisis SHAP coinciden: el texto separa sobre todo el contenido infantil (*suitable* y *disturbing* comparten personajes, pero no el mismo vocabulario), mientras que las métricas de interacción separan *restricted* e *irrelevant*, que están en los extremos de la mediana de vistas (1,348,394 y 10,436, respectivamente; Tabla II). Agregar los metadatos a la regresión logística sube el F1 macro de 0.672 a 0.710 y el recall de *restricted* de 0.359 a 0.566.

Los hiperparámetros importan menos que la representación. El ajuste apenas cambió el F1 macro de la regresión logística (0.710 en ambos casos) y la mejor configuración de LightGBM fue la más regularizada. El límite del desempeño está en la información disponible y no en el ajuste fino. El F1 macro en prueba (0.725) es similar al de validación cruzada (0.710), lo que indica que la selección del modelo no sobreajustó las particiones.

Generalización fuera del ground truth. La Sección VI-E muestra la otra cara del resultado: el mismo peso de las métricas de interacción que ayuda a detectar *restricted* en el ground truth produce muchas alertas en videos populares no infantiles. El modelo es fiable dentro de la distribución con la que se entrenó, pero no es directamente transferible a una plataforma abierta.

VII-B. Limitaciones

Además de las limitaciones del análisis exploratorio (Sección II-K), el diseño del proyecto tiene las siguientes:

- **Solo metadatos:** el modelo no observa el video ni el audio. Un video perturbador con título, descripción y tags inocuos es, por construcción, indetectable para este enfoque, y un creador malintencionado puede modificar su texto para evadirlo, como se describe en el fenómeno Elsagate [2].
- **Vigencia temporal:** el 89.3 % de los videos del ground truth se publicó entre 2014 y 2018, y los más recientes son de 2019. Desde entonces cambiaron las tendencias de contenido infantil y la propia plataforma: por ejemplo, en noviembre de 2021 YouTube dejó de mostrar públicamente el número de dislikes [11], una de las variables del modelo, que podría no estar disponible para videos actuales.
- **Duración sin transformar:** a diferencia de los conteos, `duration_seconds` entra al modelo solo estandarizada, sin $\log(1 + x)$, y conserva 173 outliers (3.6 %, Tabla IV); en un modelo lineal, unos pocos videos muy largos pueden dominar su coeficiente. No se corrigió para no cambiar el modelo ya evaluado en prueba.
- **Métricas de interacción como fotografía:** vistas, likes y comentarios se midieron una sola vez y dependen de la antigüedad del video, por lo que un video reciente con pocas vistas no es comparable con uno de años de antigüedad.
- **Etiquetas y tamaño:** el ground truth tiene 4,797 videos y solo 419 de la clase *restricted*; las etiquetas provienen de anotadores humanos y la frontera entre *suitable* y *disturbing* es en parte subjetiva.
- **Conjuntos adicionales sin etiquetas:** fuera del ground truth solo existe la predicción binaria del clasificador original, que no es una etiqueta verdadera; además, el corpus consolidado asigna un único conjunto de origen a cada video. Por eso las preguntas PI2 y PI3 se responden como comprobaciones de consistencia y no como medidas de eficacia.
- **Asociaciones con canales y series:** aunque la validación agrupada evita evaluar sobre canales vistos, el modelo puede aprender términos ligados a franquicias concretas (por ejemplo, *spiderman* o *peppa*) que perderían valor si cambian las tendencias.

VII-C. Consideraciones éticas

- **Costo asimétrico de los errores:** un falso negativo en *disturbing* o *restricted* significa que un niño de 1 a 5 años puede ver contenido violento, sexual o aterrador presentado como infantil, mientras que un falso positivo genera, como mucho, una revisión innecesaria. Por eso la evaluación prioriza el recall de estas dos clases frente a la exactitud global. El análisis de errores (Sección VI-D) confirma este riesgo: el 28.6 % de los videos *disturbing* no se detectaron, muchos con títulos de apariencia infantil como *"JooJooTV 4K | THE LITTERER | Kids Cartoons"* (predicho como *suitable* con 95 % de confianza); y el 45.0 % de los videos *restricted* tampoco se detectaron, incluyendo títulos como *"Spider Man vs Elsa | Frozen Elsa and Spider Man GTA 5"* (predicho como *suitable*).
- **Apoyo, no reemplazo, de la moderación humana:** el modelo está pensado para priorizar videos para revisión humana, no para restringir o eliminar contenido de forma automática. Una decisión automática sin revisión afectaría a creadores legítimos: la Tabla III muestra que el contenido infantil apropiado y el perturbador comparten personajes y vocabulario (por ejemplo, el 31.0 % de los videos con el tag *elsa* son *suitable* y el 60.0 % *disturbing*), por lo que los falsos positivos recaerían precisamente sobre contenido infantil legítimo.

- **Sesgos de representación:** el modelo solo conoce los canales, idiomas y tipos de contenido presentes en el ground truth. Contenido de comunidades o idiomas poco representados puede clasificarse peor, y estos errores no son visibles en las métricas globales.
- **Transparencia:** un sistema de apoyo a la moderación debe poder explicar sus decisiones. Por ello se priorizan representaciones interpretables (términos de TF-IDF, longitud del título, métricas de interacción) y se analiza la importancia de las características, de modo que un moderador pueda ver qué señales motivaron cada alerta.
- **Uso de los datos:** el dataset contiene solo metadatos públicos de los videos, sin información personal de los espectadores ni de menores. Se usa con fines académicos y citando a sus autores [4], [5], cuyo acceso en Zenodo es restringido.

VIII. Conclusiones

- **PI1 (H1 se cumple):** los metadatos permiten distinguir las cuatro clases con un desempeño muy superior al baseline. El modelo final alcanza un F1 macro de 0.725 en prueba, sobre canales no vistos, frente a 0.138 del modelo de clase mayoritaria en el mismo conjunto, y un AUC macro de 0.914. Sin embargo, la detección no es suficiente para un uso automático: el recall es de 0.714 en *disturbing* y de 0.550 en *restricted*, y los videos con títulos de apariencia infantil siguen siendo indetectables solo con el texto.
- **PI2 (H2 no se cumple):** en los videos nuevos de `elsagate_related`, el modelo predice como inapropiados el 21.78 %, frente al 0.55 % del clasificador original, y la concordancia entre ambos no supera al azar (kappa ≈ 0).
- **PI3 (H3 no se cumple):** en `other_child_related`, `random` y `popular`, la proporción de alertas (6.7 % a 12.0 %) es un orden de magnitud mayor que la del clasificador original, aunque se mantiene el orden de riesgo esperado (Elsagate primero, videos aleatorios al final).

Los principales aprendizajes son tres. Primero, el texto y las métricas de interacción son complementarios: el texto identifica el contenido infantil perturbador, y la interacción, el contenido restringido. Segundo, con muchos términos y pocos ejemplos, un modelo lineal sobre el TF-IDF completo supera a los modelos de árboles. Tercero, validar agrupando por canal y probar fuera del ground truth revela limitaciones que las métricas de prueba no muestran, en particular la sensibilidad al cambio de distribución. Por ello, el modelo es adecuado como herramienta para priorizar la revisión humana dentro de plataformas infantiles, no como filtro automático.

IX. Trabajo Futuro

Los resultados obtenidos sugieren las siguientes líneas de mejora:

1. **Incorporación de miniaturas (thumbnails):** el modelo actual no observa el contenido visual. Una CNN sobre las miniaturas podría detectar señales que el texto no puede capturar (personajes en situaciones perturbadoras, colores o composiciones atípicas), especialmente para los 55 falsos negativos de *disturbing* con títulos genéricos.
2. **Embeddings preentrenados:** sustituir TF-IDF por embeddings de modelos de lenguaje (BERT, multilingual) para capturar semántica contextual y manejar mejor el vocabulario infantil mezclado con contenido adulto, que es precisamente donde el modelo falla en *restricted* (45 % de falsos negativos).
3. **Actualización del dataset:** los datos son de 2014–2019 y YouTube retiró el contador público de dislikes en 2021 [11]. Un dataset más reciente permitiría evaluar la vigencia del modelo y reducir el sesgo temporal.
4. **Recalibración ante el cambio de distribución:** la Sección VI-E muestra que el modelo genera muchas más alertas fuera del ground truth, sobre todo en *restricted*. Ampliar el entrenamiento con contenido general no infantil, ajustar los umbrales de decisión por clase o etiquetar a mano una muestra de los desacuerdos permitiría medir y reducir estos falsos positivos.

Referencias

[1] Brandwatch, "23 YouTube stats and facts you should know," 2026, [Online]. Available: https://www.brandwatch.com/blog/youtube-stats/.

[2] United States Cybersecurity Magazine, "ElsaGate: The problem with algorithms," [Online]. Available: https://www.uscybersecurity.net/elsagate/.

[3] YouTube, "Using technology to more consistently apply age restrictions," YouTube Official Blog, Sep. 2020, [Online]. Available: https://blog.youtube/news-and-events/using-technology-more-consistently-apply-age-restrictions/.

[4] K. Papadamou, A. Papasavva, S. Zannettou, J. Blackburn, N. Kourtellis, I. Leontiadis, G. Stringhini, and M. Sirivianos, "Disturbed YouTube for kids: Characterizing and detecting inappropriate videos targeting young children," in *Proc. Int. AAAI Conf. Web Soc. Media*, vol. 14, no. 1, 2020, pp. 522–533.

[5] K. Papadamou *et al.*, "Dataset for Disturbed YouTube for Kids: Characterizing and detecting inappropriate videos targeting young children," Zenodo, 2020, [Data set]. doi: 10.5281/zenodo.3632781.

[6] Google, "YouTube Data API v3," [Online]. Available: https://developers.google.com/youtube/v3.

[7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[8] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 3146–3154.

[9] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 4765–4774.

[10] J. Cohen, "A coefficient of agreement for nominal scales," *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.

[11] YouTube, "An update to dislikes on YouTube," Nov. 2021, [Online]. Available: https://blog.google/intl/en-mena/product-updates/connect-communicate/youtube-dislikes/.

[12] A. Urbina, M. Ocampo, L. Chocce, and M. Lazón, "Machine-learning-proyect," https://github.com/ADRIAN0819/Machine-Learning-Proyect, 2026, repositorio de GitHub.